Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Bachelorarbeit

Daniel Kirchner

Skalierbare Datenanalyse mit Apache Spark

Architekturanalyse und Performancetests in verschiedenen Anwendungsfällen

Fakultät Technik und Informatik
Studiendepartment Informatik

Faculty of Engineering and Computer Science
Department of Computer Science

Daniel Kirchner

Skalierbare Datenanalyse mit Apache Spark

Architekturanalyse und Performancetests in verschiedenen Anwendungsfällen

Bachelorarbeit eingereicht im Rahmen der Bachelorprüfung

im Studiengang Bachelor of Science Angewandte Informatik
am Department Informatik
der Fakultät Technik und Informatik
der Hochschule für Angewandte Wissenschaften Hamburg

Betreuender Prüfer: Prof. Dr. Kahlbrandt
Zweitgutachter: Prof. Dr. Zweitprüfer

Eingereicht am: 1. Januar 2345

Daniel Kirchner

Thema der Arbeit
Skalierbare Datenanalyse mit Apache Spark Architekturanalyse und Performancetests in verschiedenen Anwendungsfällen

Stichworte
Schlüsselwort 1, Schlüsselwort 2

Kurzzusammenfassung
Dieses Dokument …
Daniel Kirchner

Title of the paper
Scalable Data Analysis with Apache Spark

Keywords
keyword 1, keyword 2

Abstract
This document …

Inhaltsverzeichnis

1 Einführung **1**
- 1.1 Motivation . . . 1
- 1.2 Kontextabgrenzung . . . 2

2 Vorstellung von Apache Spark **3**
- 2.1 Überblick . . . 3
- 2.2 Kernkonzepte . . . 3
  - 2.2.1 Resilient Distributed Datasets . . . 3
  - 2.2.2 Lineage . . . 3
  - 2.2.3 DAG Scheduler . . . 3
- 2.3 Standardbibliotheken . . . 3
  - 2.3.1 Spark SQL . . . 3
  - 2.3.2 MLlib . . . 3
  - 2.3.3 Streaming . . . 3
  - 2.3.4 GraphX . . . 3
- 2.4 Verwandte Produkte . . . 3
  - 2.4.1 YARN . . . 3
  - 2.4.2 Mesos . . . 3
  - 2.4.3 Flink . . . 3

3 Implementation von Anwendungsfällen **4**
- 3.1 Beispiel 1 - Hot Topics in der Spark Community . . . 4
  - 3.1.1 Beschreibung des Problems . . . 4
  - 3.1.2 Hardwarekontext und Performance-Basisdaten . . . 4
  - 3.1.3 Architekturübersicht . . . 6
  - 3.1.4 Detailierte Lösungsbeschreibung . . . 6
  - 3.1.5 Ergebnisse . . . 6
- 3.2 Beispiel 2 - (Evaluierung einer spark-basierten Implementation von CDOs auf einem HPC Cluster mit nicht-lokalem Storage) . . . 6
  - 3.2.1 Beschreibung des Problems . . . 6
  - 3.2.2 Hardwarekontext und Performance-Basisdaten . . . 6
  - 3.2.3 Architekturübersicht . . . 6
  - 3.2.4 Detailierte Lösungsbeschreibung . . . 6
  - 3.2.5 Ergebnisse . . . 6

4 Schlussbetrachtung **7**
4.1 Kritische Würdigung der Ergebnisse 7
4.2 Ausblick und offene Punkte 7

Listings

1 Einführung

1.1 Motivation

Die Entwicklung und Verbesserung von Frameworks zur Verarbeitung großer Datenmengen ist zur Zeit hochaktuell und sehr im Fokus von Medien und Unternehmen [VERWEIS]. Verschiedene Programme und Paradigmen konkurrieren um die schnellste, bequemste und stabilste Art großen Datenmengen einen geschäftsfördenden Nutzen abzuringen.

Unter dem Begriff „große Datenmengen“ oder „Big Data“ werden solche Datenmengen zusammengefasst, die die Kriterien Volume, Velocity, Variety [VERWEIS, Doug Laney] erfüllen oder „Datenmengen, die nicht mehr unter Auflage bestimmter SLAs auf einzelnen Maschinen verarbeitet werden können“ [VERWEIS, Hadoop/Yarn Entwickler].

Als Unternehmen, das früh mit solchen Datenmengen konfrontiert war implementierte Google das Map-Reduce Paradigma [VERWEIS] als Framework zur Ausnutzung vieler kostengünstiger Rechner um Webseiten einzustufen und für andere Aufgaben [VERWEIS].

In Folge der Veröffentlichung ihrer Idee im Jahr 2005 [VERWEIS] wurde Map-Reduce in Form der OpenSource Implementation Hadoop (gemeinsam mit einer Implementation des Google File Systems GFS, u.a.) [VERWEIS] zum de-facto Standard für Big-Data-Analyseaufgaben [VERWEIS?].

Reines Map-Reduce als Programmierparadigma zur effizienten Verarbeitung großer Datenmengen zeigt jedoch in vielen Anwendungsfällen Schwächen:

- Daten, die in hoher Frequenz verändert werden erfordern das ständige Neustarten eines Map-Reduce-Jobs. Iterative Algorithmen sind also nicht vorgesehen.
- Die Anfrage an ein solches System erfolgt in Form von kleinen Programmen. Dieses Verfahren ist offensichtlich nicht so deklarativ und leicht erlernbar wie SQL-Anfragen an klassische Datenbanken.

In der Folge entstanden viele Ansätze dieses Paradigma zu ersetzen, zu ergänzen oder durch übergeordnete Ebenen und High-Level-APIs zu vereinfachen.

- [VERWEIS: A survey of large scale...] oder Aufzählung.

Eine der Alternativen zu der Map-Reduce-Komponente in Hadoop die „general engine for large-scale data processing“ Apache Spark.

Ein Indiz für das steigende Interesse an diesem Produkt liefert unter anderem ein Vergleich des Interesses an Hadoop und Spark auf Google:

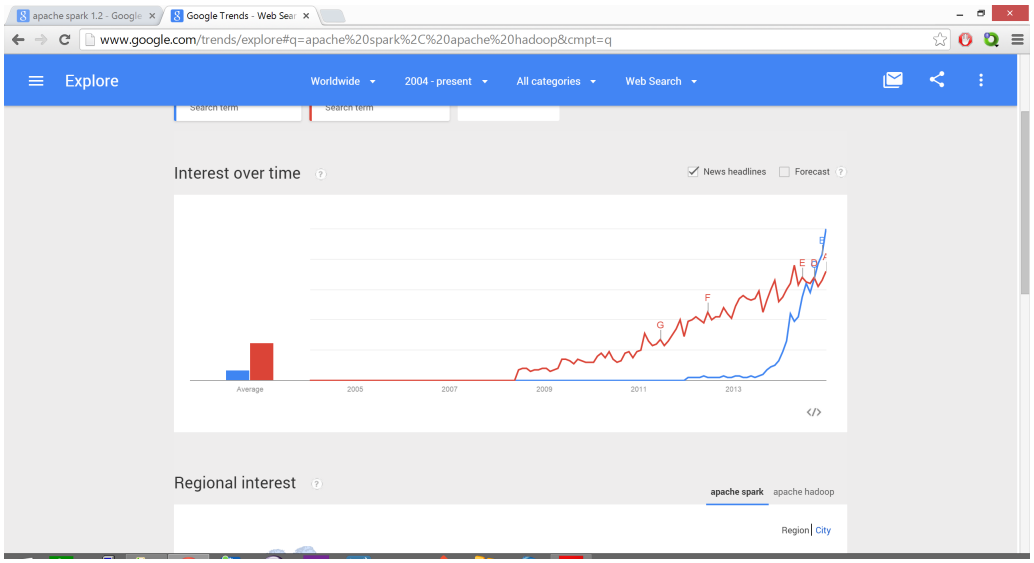

1.2 Kontextabgrenzung

2 Vorstellung von Apache Spark

2.1 Überblick

2.2 Kernkonzepte

— Warum ist Spark so schnell —

2.2.1 Resilient Distributed Datasets

2.2.2 Lineage

2.2.3 DAG Scheduler

2.3 Standardbibliotheken

— Warum ist Spark so einfach —

2.3.1 Spark SQL

2.3.2 MLlib

2.3.3 Streaming

2.3.4 GraphX

2.4 Verwandte Produkte

— Ergänzende oder konkurrierende Produkte —

2.4.1 YARN

2.4.2 Mesos

2.4.3 Flink

3 Implementation von Anwendungsfällen

Im Folgenden wird Apache Spark im Rahmen zweier grundsätzlich verschiedener Anwendungsfälle betrachtet.

Eine typische Anwendung mit verteilten lokalem Storage (HDFS) und Spark als „Client“ eines bestehenden Yarn Clustermanagers. Commodity Hardware (Rasperry Pi Cluster).

Eine untypische Anwendung mit verteiltem entfernten Storage und dem Spark Standalone Clustermanager. HPC Hardware („Thunder“ des Hamburger KlimaCampus).

3.1 Beispiel 1 - Hot Topics in der Spark Community

Fusion von Tweets und Mailinglisten https://spark.apache.org/docs/1.3.0/mllib-feature-extraction.html Implementation auf einem Raspberry Pi Cluster mit HDFS und Yarn Clustermanager

3.1.1 Beschreibung des Problems

3.1.2 Hardwarekontext und Performance-Basisdaten

— hier kommen die eingesetzten systeme, und relevante laufzeitmessungen (netzwerk, storage, cpu) hin —

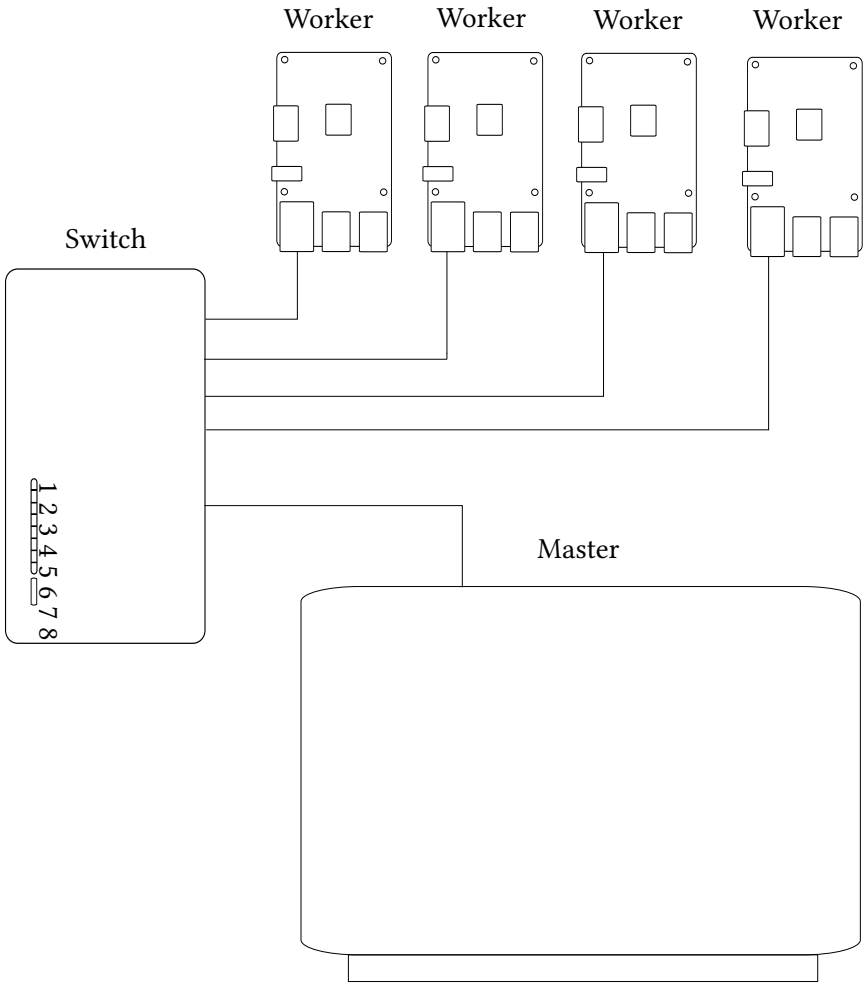
Worker
Worker
Worker
Worker
Switch
1 2 3 4 5 6 7 8
Master

3.1.3 Architekturübersicht

— hier kommen Verteilungs- und Komponentendiagramm hin —

3.1.4 Detailierte Lösungsbeschreibung

— hier kommen laufzeitdiagramme und codeschnipsel hin —

3.1.5 Ergebnisse

3.2 Beispiel 2 - (Evaluierung einer spark-basierten Implementation von CDOs auf einem HPC Cluster mit nicht-lokalem Storage)

Implementation ausgewählter CDOs (sehr wenige, möglicherweise nur 1-2) mit der Core-API von Spark. Testlauf auf einem HPC Cluster mit nicht-lokalem, allerdings per Infiniband angeschlossenen Storage. Insbesondere Betrachtung des Skalierungsverhaltens und der „Sinnhaftigkeit“.

3.2.1 Beschreibung des Problems

Erläuterung von CDOs (Climate Data Operators).

3.2.2 Hardwarekontext und Performance-Basisdaten

— hier kommen die eingesetzten systeme, und relevante laufzeitmessungen (netzwerk, storage, cpu) hin —

3.2.3 Architekturübersicht

— hier kommen Verteilungs- und Komponentendiagramm hin —

3.2.4 Detailierte Lösungsbeschreibung

— hier kommen laufzeitdiagramme und codeschnipsel hin —

3.2.5 Ergebnisse

4 Schlussbetrachtung

4.1 Kritische Würdigung der Ergebnisse

4.2 Ausblick und offene Punkte

See also One und Two (2010).

Literaturverzeichnis

[One und Two 2010] One, Author ; Two, Author: A Sample Publication. (2010)

Hiermit versichere ich, dass ich die vorliegende Arbeit ohne fremde Hilfe selbständig verfasst und nur die angegebenen Hilfsmittel benutzt habe.

Hamburg, 1. Januar 2345 Daniel Kirchner