



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Bachelorarbeit

Daniel Kirchner

Skalierbare Datenanalyse mit Apache Spark

Zugrunde liegende Konzepte und praktische Anwendung

*Fakultät Technik und Informatik
Studiendepartment Informatik*

*Faculty of Engineering and Computer Science
Department of Computer Science*

Daniel Kirchner

Skalierbare Datenanalyse mit Apache Spark
Zugrunde liegende Konzepte und praktische Anwendung

Bachelorarbeit eingereicht im Rahmen der Bachelorprüfung

im Studiengang Bachelor of Science Angewandte Informatik
am Department Informatik
der Fakultät Technik und Informatik
der Hochschule für Angewandte Wissenschaften Hamburg

Betreuender Prüfer: Prof. Dr. Kahlbrandt
Zweitgutachter: Prof. Dr. Zweitprüfer

Eingereicht am: 1. Januar 2345

Daniel Kirchner

Thema der Arbeit

Skalierbare Datenanalyse mit Apache Spark Zugrunde liegende Konzepte und praktische Anwendung

Stichworte

Schlüsselwort 1, Schlüsselwort 2

Kurzzusammenfassung

Dieses Dokument ...

Daniel Kirchner

Title of the paper

Scalable Data Analysis with Apache Spark

Keywords

keyword 1, keyword 2

Abstract

This document ...

Inhaltsverzeichnis

1	Einführung	1
1.1	Motivation	1
1.2	Kontextabgrenzung	2
2	Vorstellung von Apache Spark	4
2.1	Überblick	4
2.2	Kernkonzepte	4
2.2.1	Resilient Distributed Datasets	4
2.2.2	Lineage	4
2.2.3	DAG Scheduler	4
2.3	Standardbibliotheken	4
2.3.1	Spark SQL	4
2.3.2	MLlib	4
2.3.3	Streaming	4
2.3.4	GraphX	4
2.4	Betrieb und Security	4
2.5	Entwicklergemeinschaft	4
2.6	Verwandte Produkte	5
2.6.1	YARN	5
2.6.2	Mesos	5
2.6.3	Flink	5
3	Spark in der Praxis	6
3.1	Echtzeitbewertung von Twitter-Accounts nach ihrer Relevanz für Spark	6
3.1.1	Beschreibung des Problems	6
3.1.2	Hardwarekontext und Performance-Basisdaten	6
3.1.3	Architekturübersicht	9
3.1.4	Detaillierte Lösungsbeschreibung	9
3.1.5	Ergebnisse	11
3.2	Evaluierung einer spark-basierten Implementation von CDOs auf einem HPC Cluster mit nicht-lokalem Storage	12
3.2.1	Beschreibung des Problems	12
3.2.2	Hardwarekontext und Performance-Basisdaten	12
3.2.3	Architekturübersicht	12
3.2.4	Detaillierte Lösungsbeschreibung	12

3.2.5	Ergebnisse	12
4	Schlussbetrachtung	13
4.1	Kritische Würdigung der Ergebnisse	13
4.2	Ausblick und offene Punkte	13

Listings

3.1	Treiber für Testanwendung (Programmiersprache Scala)	9
-----	--	---

1 Einführung

1.1 Motivation

Die Entwicklung und Verbesserung von Frameworks zur Verarbeitung großer Datenmengen ist zur Zeit hochaktuell und sehr im Fokus von Medien und Unternehmen [VERWEIS]. Verschiedene Programme und Paradigmen konkurrieren um die schnellste, bequemste und stabilste Art großen Datenmengen einen geschäftsfördernden Nutzen abzurufen.

Mit dem Begriff „große Datenmengen“ oder „Big Data“ werden in dieser Arbeit solche Datenmengen zusammengefasst, die die Kriterien Volume, Velocity, Variety [VERWEIS, Doug Laney] erfüllen oder „Datenmengen, die nicht mehr unter Auflage bestimmter SLAs auf einzelnen Maschinen verarbeitet werden können“ [VERWEIS, Hadoop/Yarn Entwickler].

Als Unternehmen, das früh mit solchen Datenmengen konfrontiert war implementierte Google das Map-Reduce Paradigma [VERWEIS] als Framework zur Ausnutzung vieler kostengünstiger Rechner um Webseiten einzustufen und für andere Aufgaben [VERWEIS].

In Folge der Veröffentlichung ihrer Idee im Jahr 2005 [VERWEIS] wurde Map-Reduce in Form der OpenSource Implementation Hadoop (gemeinsam mit einer Implementation des Google File Systems GFS, u.a.) [VERWEIS] zum de-facto Standard für Big-Data-Analyseaufgaben [VERWEIS?].

Reines Map-Reduce (nach Art von Hadoop) als Programmierparadigma zur Verarbeitung großer Datenmengen zeigt jedoch in vielen Anwendungsfällen Schwächen:

- Daten, die in hoher Frequenz entstehen und schnell verarbeitet werden sollen erfordern häufiges Neustarten von Map-Reduce-Jobs. Die Folge ist kostspieliger Overhead durch Verwaltung/Scheduling der Jobs und gegebenenfalls wiederholtem Einlesen von Daten.
- Algorithmen die während ihrer Ausführung iterativ Zwischenergebnisse erzeugen und auf vorherige angewiesen sind (häufig bei Maschinenlernalgorithmen) können nur durch

persistentes Speichern der Daten und wiederholtes Einlesen zwischen allen Iterationsschritten implementiert werden.


- Anfragen an ein solches reines Map-Reduce-System erfolgen imperativ in Form von kleinen Programmen. Dieses Verfahren ist offensichtlich nicht so intuitiv und leicht erlernbar wie deklarative Abfragesprachen klassischer Datenbanken (z.B. SQL).

In der Folge dieser Probleme entstanden viele Ansätze dieses Paradigma zu ersetzen, zu ergänzen oder durch übergeordnete Ebenen und High-Level-APIs zu vereinfachen.

- [VERWEIS: A survey of large scale...] oder Aufzählung.

Eine der Alternativen zu der Map-Reduce-Komponente in Hadoop ist die „general engine for large-scale data processing“ Apache Spark.

Ein Indiz für das steigende Interesse an diesem Produkt liefert unter anderem ein Vergleich des Interesses an Hadoop und Spark auf Google:



1.2 Kontextabgrenzung

Das Ziel dieser Arbeit ist es einen Einblick in die grundlegenden Konzepte und Anwendungsmöglichkeiten von Apache Spark zu vermitteln.

Für ein tieferes Verständnis werden zwei Anwendungsfälle untersucht und deren Lösung detailliert dokumentiert und bewertet.

Nur am Rande wird betrachtet:

- Vergleich mit ähnlichen Produkten
- Empirische Messung des Skalierungsverhaltens
- Konkrete Hinweise zu Installation und Betrieb

2 Vorstellung von Apache Spark

2.1 Überblick

2.2 Kernkonzepte

— Warum ist Spark schnell, ausfallsicher, secure (und wo vielleicht nicht)? — — Annahme: Durchsatzfaktoren RAM, Netzwerk, Festplatte —

2.2.1 Resilient Distributed Datasets

2.2.2 Lineage

2.2.3 DAG Scheduler

2.3 Standardbibliotheken

— Warum ist Spark so einfach (und wo vielleicht nicht)? —

2.3.1 Spark SQL

2.3.2 MLlib

2.3.3 Streaming

2.3.4 GraphX

2.4 Betrieb und Security

2.5 Entwicklergemeinschaft

— Herkunft, Apache Foundation, Entwicklungsphilosophien, Anzahl Entwickler, ... —

2.6 Verwandte Produkte

— Ergänzende oder konkurrierende Produkte —

2.6.1 YARN

2.6.2 Mesos

2.6.3 Flink

3 Spark in der Praxis

Im Folgenden wird Apache Spark im Rahmen zweier grundsätzlich verschiedener Anwendungsfälle betrachtet.

Beispiel 1: Eine typische Anwendung mit verteiltem lokalem Storage (HDFS) und Spark als „Client“ eines bestehenden Yarn Clustermanagers. — Commodity Hardware (Raspberry Pi Cluster).

Beispiel 2: Eine untypische Anwendung mit verteiltem entfernten Storage und dem Spark Standalone Clustermanager. — HPC Hardware („Thunder“ des Hamburger KlimaCampus).

3.1 Echtzeitbewertung von Twitter-Accounts nach ihrer Relevanz für Spark

— Fusion von Tweets und Mailinglisten <https://spark.apache.org/docs/1.3.0/mllib-feature-extraction.html>
Implementation auf einem Raspberry Pi Cluster mit HDFS und Yarn Clustermanager —

3.1.1 Beschreibung des Problems

— Es sollen die beiden Spark Mailingslisten (Developer, User) zur Identifikation relevanter und aktueller Themen genutzt werden. Mit den so bewerteten Begriffen können wiederum Tweets bewertet werden. Mit den Tweets können dann ganze Accounts nach ihrer Relevanz beurteilt werden. — — Zwei Datenquellen: Tweets (Nahe-Echtzeit), Entwickler-E-mails (Sporadisch) — — Stichworte: HDFS, Yarn, Rasperry Pi Cluster, Machine Learning, Feature Extraction, Big Data Life Cycle —

3.1.2 Hardwarekontext und Performance-Basisdaten

— hier kommen die eingesetzten systeme, und relevante laufzeitmessungen (netzwerk, storage, cpu) hin —


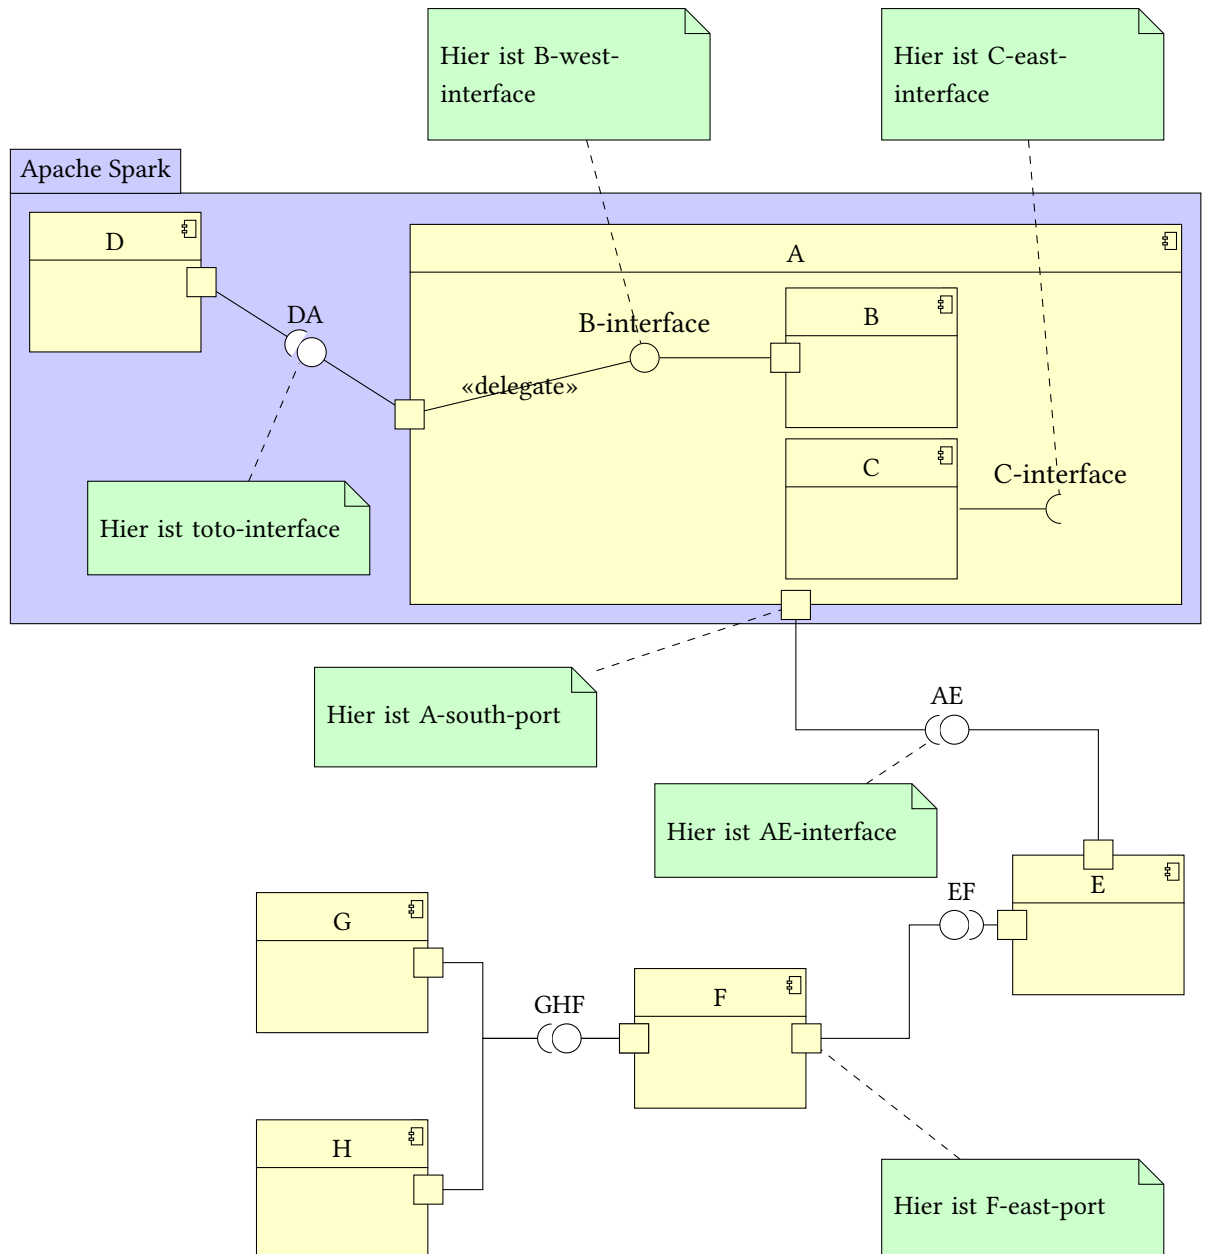


Tabelle 3.1: –DUMMY– Netzwerkdurchsatz

Nachrichtengröße	Worker \rightarrow <i>Worker</i>	Master \rightarrow <i>Worker</i>	Worker \rightarrow <i>Master</i>
1kB	50ms	837ms	970ms
64kB	47ms	877ms	230ms
1MB	31ms	25ms	415ms
64MB	35ms	144ms	2356ms

3.1.3 Architekturübersicht




3.1.4 Detaillierte Lösungsbeschreibung

— hier kommen diagramme und codeschnipsel hin —

```
1 import org.apache.spark.SparkContext
```

```
2 import org.apache.spark.SparkContext._
3 import org.apache.spark.SparkConf
4
5 object ScalaApp {
6   val my_spark_home = "/home/daniel/projects/spark-1.1.0"
7
8   def main(args: Array[String]): Unit = {
9     val logFile = my_spark_home + "/README.md"
10
11     val conf = new SparkConf().setAppName("ScalaApp")
12     val sc = new SparkContext(conf)
13
14     val parList1 = sc.parallelize(List(1,2,3,4,5,6))
15     val parList2 = sc.parallelize(List(5,6,7,8,9,10))
16     val str1 =
17       "RDD1:_\%" .format(parList1.collect().deep.mkString("_"))
18     val str2 =
19       "RDD2:_\%" .format(parList2.collect().deep.mkString("_"))
20     val str3 =
21       "#_of_RDD1:_\%" .format(parList1.count())
22     val str4 =
23       "Intersect:_\%" .format(parList1.intersection(parList2).collect())
24     val str5 =
25       "Intersect:_\%" .format(parList1.cartesian(parList2).collect())
26   }
27 }
```

Listing 3.1: Treiber für Testanwendung (Programmiersprache Scala)



3.1.5 Ergebnisse

— Tabellen und Diagramme Ergebnissen, evt. Skalierungsverhalten — — Bewertung —

3.2 Evaluierung einer spark-basierten Implementation von CDOs auf einem HPC Cluster mit nicht-lokalem Storage

— Implementation ausgewählter CDOs (sehr wenige, möglicherweise nur 1-2) mit der Core-API von Spark. Testlauf auf einem HPC Cluster mit nicht-lokalem, allerdings per Infiniband angeschlossenen Storage. Insbesondere Betrachtung des Skalierungsverhaltens und der „Sinnhaftigkeit“. —

3.2.1 Beschreibung des Problems

— Erläuterung von CDOs (Climate Data Operators). —

3.2.2 Hardwarekontext und Performance-Basisdaten

— hier kommen die eingesetzten systeme, und relevante laufzeitmessungen (netzwerk, storage, cpu) hin —

3.2.3 Architekturübersicht

— hier kommen Verteilungs- und Komponentendiagramm hin —

3.2.4 Detaillierte Lösungsbeschreibung

— hier kommen laufzeitdiagramme und codeschnipsel hin —

3.2.5 Ergebnisse

— Tabellen und Diagramme Ergebnissen, evt. Skalierungsverhalten — — Bewertung —

4 Schlussbetrachtung

4.1 Kritische Würdigung der Ergebnisse

4.2 Ausblick und offene Punkte

See also [One und Two \(2010\)](#).

Literaturverzeichnis

[One und Two 2010] ONE, Author ; TWO, Author: A Sample Publication. (2010)

Hiermit versichere ich, dass ich die vorliegende Arbeit ohne fremde Hilfe selbständig verfasst und nur die angegebenen Hilfsmittel benutzt habe.

Hamburg, 1. Januar 2345 Daniel Kirchner
